Tomasz Zapiórkowski

Podstawy Sztucznej Inteligencji – Sprawozdanie

Scenariusz 2

Opis wykonywanego ćwiczenia:
Celem ćwiczenia było poznanie i działanie sieci neuronowych oraz uczenie rozpoznawania wielkości liter.

Wykonane zadania:

1. Wygenerowano dane uczące i testujące, zawierające 10 wielkich i 10 małych liter alfabetu łacińskiego w postaci dwuwymiarowej tablicy 7x5, reprezentowanej w kodzie jako jednowymiarowa tablica 35 elementowa
2. Wykorzystano narzędzie PyBrain do stworzenia 2 sieci neuronowych (FeedForward i Recurrent) wraz z modyfikacją warstwy uczącej (Sigmoidalna i Tanh).
3. Uczono sieci modyfikując współczynnik uczenia.
4. Testowano poprawność działania sieci.

Specyfikacja:
Sieć neuronowa typu FeedForward opiera się na założeniu, że połączenia między neuronami nie tworzą cyklu, czyli informacja cały czas posuwa się w jednym kierunku, naprzód, zaczynając od warstwy wejścia, przez warstwę ukrytą(jeżeli istnieje) aż do warstwy wyjścia. Nie ma cyklów ani pętli w takiej sieci.

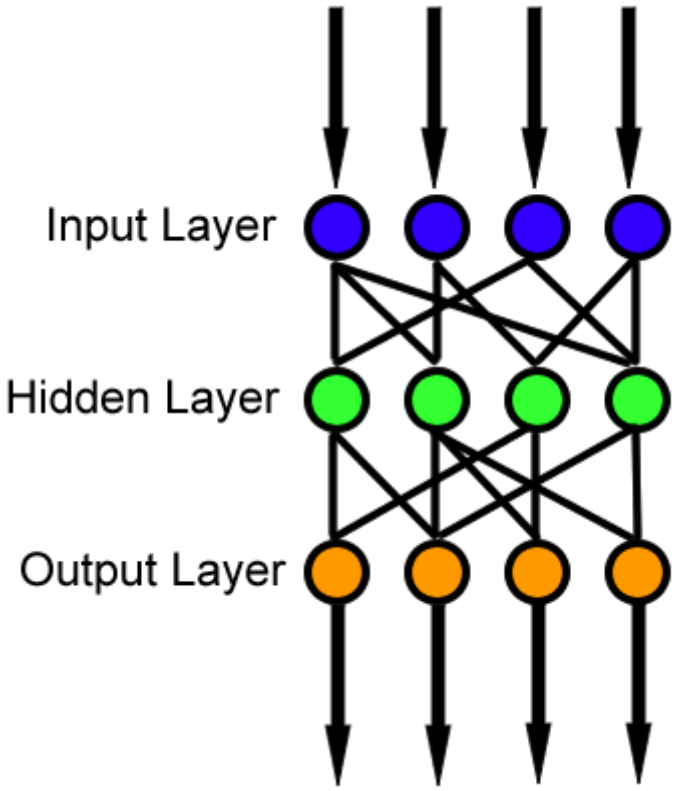

Schemat sieci typu FeedForward

Sieć neuronowa typu Recurrent to sieć, w której neurony połączone są za pomocą kierunkowych cykli. W sieciach rekurencyjnych istnieją sprzężenia zwrotne między wejściem, a wyjściem. Zmiana stanu jednego neuronu przenosi się przez masowe sprzężenie zwrotne na całą sieć.

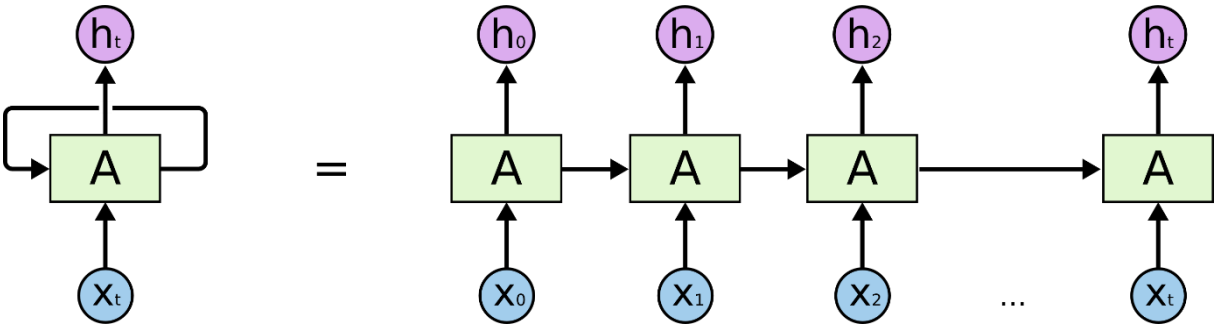

Schemat sieci typu Reccurent

Sygnał wyjściowy neuronu w takiej sieci, gdzie f to aktywacja neuronu, a u to sygnałem aktywacji, to:

$$y_i = f(u_i) = f\left(\sum_{j=1}^{N} W_{ij} x_j\right)$$

Neuron sigmoidalny jest budową zbliżony do perceptronu, różni się on przede wszystkim funkcją aktywacji i zwracaną wartością. Wykorzystuje on ciągłą funkcję aktywacji.
W neuronie sigmoidalnym do obliczenia nowej wagi wykorzystywana jest pochodna funkcji aktywacji: $\Delta wij(k+1) = -\eta\delta ixj + \alpha\Delta wij(k)$
gdzie:
i - numer neutronu
j - numer wejścia
w - waga
η - learning rate
δ - pochodna funkcji aktywacji

$$\delta = \frac{\mathrm{d}f}{\mathrm{d}x} = \frac{e^{\beta x}}{(e^{\beta x} + 1)^2}$$

Neuron tanh jest to modyfikacja neurona liniowego, jednak funkcja aktywacji nie jest liniowa a hyperboliczna. Konkretnie jest to tangens hiperboliczny.

Algorytm wstecznej propagacji błędu: metoda uczenia sieci wielowarstwowej, w której błąd ostatniej warstwy jest przesyłany wstecz i wykorzystywany do zmiany wartości wag w poprzednich warstwach. Ogólny schemat procesu trenowania sieci wygląda następująco:

1. Ustalamy topologię sieci, tzn. liczbę warstw, liczbę neuronów w warstwach.
2. Inicjujemy wagi losowo (na małe wartości).
3. Dla danego wektora uczącego obliczamy odpowiedź sieci (warstwa po warstwie).
4. Każdy neuron wyjściowy oblicza swój błąd, oparty na różnicy pomiędzy obliczoną odpowiedzią *y* oraz poprawną odpowiedzią *t*.
5. Błędy propagowane są do wcześniejszych warstw.
6. Każdy neuron (również w warstwach ukrytych) modyfikuje wagi na podstawie wartości błędu i wielkości przetwarzanych w tym kroku sygnałów.
7. Powtarzamy od punktu 3. dla kolejnych wektorów uczących. Gdy wszystkie wektory zostaną użyte, losowo zmieniamy ich kolejność i zaczynamy wykorzystywać powtórnie.
8. Zatrzymujemy się, gdy średni błąd na danych treningowych przestanie maleć. Możemy też co jakiś czas testować sieć na specjalnej puli nieużywanych do treningu próbek testowych i kończyć trenowanie, gdy błąd przestanie maleć.

Wykonanie zadania:

Do trenowania użyto wykonanego zestawu danych z małymi i dużymi literami. W obu sieciach do rozpoznawania wielkości liter użyto po 5 neuronów.
Zastosowano algorytm propagacji wstecznej.

Wyniki:
Przykładowe zrzuty ekranu z procesu testowania:

lrate=0.1, epochs=1000

```
Total error: 1.70283945507e-05
Number of training patterns: 20
For letter A precision is 0.999624660063
MSE: 1.40880068172e-07
Letter A is capital letter
For letter C precision is 0.99933860855
MSE: 4.3743864974le-07
Letter C is capital letter
For letter I precision is 1.00053960094
MSE: 2.91169172371e-07
Letter I is capital letter
For letter G precision is 0.986185528954
MSE: 0.000190839610286
Letter G is capital letter
For letter K precision is 1.00934071641
MSE: 8.72489831305e-05
Letter K is capital letter
For letter a precision is -0.0035059465675
MSE: 1.22916613342e-05
Letter a is small letter
For letter c precision is -0.00370237985116
MSE: 1.37076165623e-05
Letter c is small letter
For letter f precision is -0.00145193589928
MSE: 2.10811785561e-06
Letter f is small letter
For letter m precision is -0.00469909306859
MSE: 2.20814756672e-05
Letter m is small letter
For letter w precision is -0.00309641676017
MSE: 9.58779675267e-06
Letter w is small letter
MSE:  1.69367374739e-05

Process finished with exit code 0
```

lrate=0.1, epochs=100

```
Total error: 0.000166810735424
Number of training patterns: 20
For letter A precision is 0.977726702988
MSE: 0.000496099759785
Letter A is capital letter
For letter C precision is 1.0001569949
MSE: 2.46473991813e-08
Letter C is capital letter
For letter I precision is 0.992699294042
MSE: 5.33003074914e-05
Letter I is capital letter
For letter G precision is 0.978076026005
MSE: 0.000480660635725
Letter G is capital letter
For letter K precision is 0.978452065722
MSE: 0.000464313471659
Letter K is capital letter
For letter a precision is 0.00014519495917
MSE: 2.10815761685e-08
Letter a is small letter
For letter c precision is 0.0238699934935
MSE: 0.00056977658938
Letter c is small letter
For letter f precision is 0.000891622134082
MSE: 7.94990029986e-07
Letter f is small letter
For letter m precision is 0.00241395386313
MSE: 5.82717325331e-06
Letter m is small letter
For letter w precision is 0.00512788112099
MSE: 2.6295164791e-05
Letter w is small letter
MSE:  0.000104855691054

Process finished with exit code 0
```

Wyniki zostały zamieszczone w formie wykresów w załączonym pliku.

Analiza:
Proces uczenia odbywał się przez ograniczoną ilość epok, początkowo 10000 a następnie 2000, gdyż te 2000 było wystarczające w testowanych przypadkach. Lrate zmieniał się w zakresie 0.01-0.5.

Dla sieci FeedForward z neuronami sigmoidalnymi przy lrate=0.01 odpowiednio niski błąd(<0.001) został osiągany przy około 1000 epokach (zależnie od wartości początkowych). Dodatkowo na wykresie widać również wyraźny skok przy około 500 epokach. Oprócz tego skoku wykres jest dosyć ciągły bez wyraźnych skoków.
Bardzo podobnie wyglądają wyniki dla lrate=0.05, z tym że odpowiednio niski błąd zostaje osiągnięty już po około 250 epokach, a skok na wykresie jest przy około 150 epokach.

Idąc dalej przy lrate=0.1 mamy analogiczną sytuację, jeszcze szybszy spadek błędu, już po 150 epokach błąd jest odpowiednio niski, a wyraźny skok widać po około 70 epokach.
Przy lrate=0.5 nie widać już tego skoku charakterystycznego dla wcześniejszych prób, jednak próg błędu zostaje osiągnięty po 40 próbach.

Kolejno przeszedłem do testowania sieci FeedForward z neuronami typu tanh. Dla lrate=0.01 próg błędu zostaje osiągnięty po 750 epokach, nie widać również wyraźnego skoku, wykres jest ciągły.
Dla lrate=0.5 próg błędu zostaje osiągnięty po 70 epokach, brak wyraźnego skoku.

Dla wszystkich powyższych konfiguracji testowana sieć poprawnie rozpoznawała wielkość liter.

Kolejno przeszedłem do testowania rekurencyjnej sieci z neuronami sigmoidalnymi. Lrate=0.01 spowodował, że odpowiednio niski błąd został osiągnięty dopiero po 1300 epokach. W dodatku sieć miała problemy z rozpoznawaniem wielkości litery ‘A’ gdzie zamiast zwracać wagę w okolicach 1, to wyniki wahały się od 0.5 do 2.
Przy lrate=0.5 sieć po około 100 epokach była odpowiednio nauczona, lecz znów powtarzał się problem z literą ‘A’.
Kolejno zmieniono konfigurację: sieć rekurencyjna z neuronami typu tanh. Dla lrate=0.01 widać wyraźną poprawę wyników. Próg błędu zostaje osiągnięty po 700 epokach, jednak nadal problem z literą ‘A’ występuje.
Ostatnią testowaną konfiguracją była powyższa z lrate=0.1, gdyż przy lrate=0.5 sieć była niestabilna i błąd rósł zamiast maleć. Co więcej nawet przy lrate=0.1 próg błędu został osiągnięty dopiero po 1100 epokach co było niewydajne, dodatkowo samo rozwiązanie było niestabilne gdyż występowały skoki na wykresie błędów.

Wnioski
Na podstawie otrzymanych wyników można stwierdzić, że do tego typu zastosowań sieć rekurencyjna nie jest odpowiednia. Po pierwsze działała tak samo albo wolniej od sieci FeedForward a w dodatku miała problem z rozpoznawaniem wielkości litery ‘A’.
Dodatkowo ewidentnie można zauważyć że neurony sigmoidalne lepiej zachowywały się przy dużym lrate. Niezależnie od typu sieci przy dużym lrate szybciej osiągały zamierzony próg błędu od neuronów typu tanh.
Neurony typu tanh za to znacznie lepiej radziły sobie przy małych lrate, przy dużych za to rozwiązania oparte na tych neuronach stawały się niestabilne.

Jednakże dla tak trywialnego zadania bardziej optymalne było wybranie wysokiego lrate co znacząco skróciło czas nauki sieci (z 1000 epok do 40 – poprawa 25 krotna).

Listing:
inputLetters.py

```
#!/usr/bin/python

from pybrain3.datasets import SupervisedDataSet

inputLettersDataSet = SupervisedDataSet(35, 1)

#A
inputLettersDataSet.addSample((
    -1, 1, 1, 1, -1,
    1, -1, -1, -1, 1,
    1, -1, -1, -1, 1,
    1, 1, 1, 1, 1,
    1, -1, -1, -1, 1,
    1, -1, -1, -1, 1,
    1, -1, -1, -1, 1
    ),
    1)

#B
inputLettersDataSet.addSample((
    1, 1, 1, 1, -1,
    1, -1, -1, -1, 1,
    1, -1, -1, -1, 1,
    1, 1, 1, 1, -1,
    1, -1, -1, -1, 1,
    1, -1, -1, -1, 1,
    1, 1, 1, 1, -1
    ),
    1)

#C
inputLettersDataSet.addSample((
    -1, 1, 1, 1, -1,
    1, -1, -1, -1, 1,
    1, -1, -1, -1, -1,
    1, -1, -1, -1, -1,
    1, -1, -1, -1, -1,
    1, -1, -1, -1, 1,
    -1, 1, 1, 1, -1
    ),
    1)

#D
inputLettersDataSet.addSample((
    1, 1, 1, 1, -1,
    1, -1, -1, -1, 1,
    1, -1, -1, -1, 1,
    1, -1, -1, -1, 1,
    1, -1, -1, -1, 1,
    1, -1, -1, -1, 1,
    1, 1, 1, 1, -1
    ),
    1)

#F
inputLettersDataSet.addSample((
    1, 1, 1, 1, 1,
    1, -1, -1, -1, -1,
    1, -1, -1, -1, -1,
```

```
    1, 1, 1, 1, -1,
    1, -1, -1, -1, -1,
    1, -1, -1, -1, -1,
    1, -1, -1, -1, -1
    ),
    1)

#G
inputLettersDataSet.addSample((
    -1, 1, 1, 1, -1,
    1, -1, -1, -1, 1,
    1, -1, -1, -1, -1,
    1, -1, 1, 1, 1,
    1, -1, -1, -1, 1,
    1, -1, -1, -1, 1,
    -1, 1, 1, 1, -1
    ),
    1)

#H
inputLettersDataSet.addSample((
    1, -1, -1, -1, 1,
    1, -1, -1, -1, 1,
    1, -1, -1, -1, 1,
    1, 1, 1, 1, 1,
    1, -1, -1, -1, 1,
    1, -1, -1, -1, 1,
    1, -1, -1, -1, 1
    ),
    1)

#I
inputLettersDataSet.addSample((
    -1, -1, 1, -1, -1,
    -1, -1, 1, -1, -1,
    -1, -1, 1, -1, -1,
    -1, -1, 1, -1, -1,
    -1, -1, 1, -1, -1,
    -1, -1, 1, -1, -1,
    -1, -1, 1, -1, -1
    ),
    1)

#K
inputLettersDataSet.addSample((
    1, -1, -1, -1, 1,
    1, -1, -1, 1, -1,
    1, -1, 1, -1, -1,
    1, 1, -1, -1, -1,
    1, -1, 1, -1, -1,
    1, -1, -1, 1, -1,
    1, -1, -1, -1, 1
    ),
    1)

#U
inputLettersDataSet.addSample((
    1, -1, -1, -1, 1,
    1, -1, -1, -1, 1,
    1, -1, -1, -1, 1,
    1, -1, -1, -1, 1,
```

```
    1, -1, -1, -1, 1,
    1, -1, -1, -1, 1,
    -1, 1, 1, 1, -1
    ),
    1)

#a
inputLettersDataSet.addSample((
    -1, -1, -1, -1, -1,
    -1, -1, -1, -1, -1,
    -1, -1, -1, -1, -1,
    -1, 1, 1, 1, -1,
    -1, 1, -1, 1, -1,
    -1, 1, -1, 1, -1,
    -1, 1, 1, 1, 1
    ),
    0)

#b
inputLettersDataSet.addSample((
    1, -1, -1, -1, -1,
    1, -1, -1, -1, -1,
    1, -1, -1, -1, -1,
    1, 1, 1, 1, -1,
    1, -1, -1, 1, -1,
    1, -1, -1, 1, -1,
    1, 1, 1, 1, -1
    ),
    0)

#c
inputLettersDataSet.addSample((
    -1, -1, -1, -1, -1,
    -1, -1, -1, -1, -1,
    -1, -1, -1, -1, -1,
    -1, 1, 1, 1, -1,
    -1, 1, -1, -1, -1,
    -1, 1, -1, -1, -1,
    -1, 1, 1, 1, -1
    ),
    0)

#d
inputLettersDataSet.addSample((
    -1, -1, -1, -1, 1,
    -1, -1, -1, -1, 1,
    -1, -1, -1, -1, 1,
    -1, -1, 1, 1, 1,
    -1, 1, -1, -1, 1,
    -1, 1, -1, -1, 1,
    -1, 1, 1, 1, 1
    ),
    0)

#f
inputLettersDataSet.addSample((
    -1, -1, 1, 1, -1,
    -1, -1, 1, -1, -1,
    -1, -1, 1, -1, -1,
    -1, 1, 1, 1, -1,
    -1, -1, 1, -1, -1,
```

```
    -1, -1, 1, -1, -1,
    -1, -1, 1, -1, -1
    ),
    0)

#h
inputLettersDataSet.addSample((
    1, -1, -1, -1, -1,
    1, -1, -1, -1, -1,
    1, -1, -1, -1, -1,
    1, 1, 1, -1, -1,
    1, -1, 1, -1, -1,
    1, -1, 1, -1, -1,
    1, -1, 1, -1, -1
    ),
    0)

#m
inputLettersDataSet.addSample((
    -1, -1, -1, -1, -1,
    -1, -1, -1, -1, -1,
    -1, -1, -1, -1, -1,
    1, 1, 1, 1, 1,
    1, -1, 1, -1, 1,
    1, -1, 1, -1, 1,
    1, -1, 1, -1, 1
    ),
    0)

#o
inputLettersDataSet.addSample((
    -1, -1, -1, -1, -1,
    -1, -1, -1, -1, -1,
    -1, -1, -1, -1, -1,
    -1, 1, 1, 1, -1,
    -1, 1, -1, 1, -1,
    -1, 1, -1, 1, -1,
    -1, 1, 1, 1, -1
    ),
    0)

#w
inputLettersDataSet.addSample((
    -1, -1, -1, -1, -1,
    -1, -1, -1, -1, -1,
    -1, -1, -1, -1, -1,
    1, -1, -1, -1, 1,
    1, -1, -1, -1, 1,
    1, -1, 1, -1, 1,
    -1, 1, -1, 1, -1
    ),
    0)

#z
inputLettersDataSet.addSample((
    -1, -1, -1, -1, -1,
    -1, -1, -1, -1, -1,
    -1, -1, -1, -1, -1,
    -1, 1, 1, 1, 1,
    -1, -1, -1, 1, -1,
    -1, -1, 1, -1, -1,
```

```
    -1, 1, 1, 1, 1
    ),
    0)
```

network.py

```
#!/usr/bin/python

from pybrain3.structure import TanhLayer

from pybrain3.structure import FeedForwardNetwork, LinearLayer,
SigmoidLayer, FullConnection, RecurrentNetwork
from pybrain3.structure.modules.biasunit import BiasUnit

# network = FeedForwardNetwork()
network = RecurrentNetwork()

inLayer = LinearLayer(35)
# hiddenLayer = SigmoidLayer(5)
hiddenLayer = TanhLayer(5)
outLayer = LinearLayer(1)
bias = BiasUnit()

network.addInputModule(inLayer)
network.addModule(bias)
network.addModule(hiddenLayer)
network.addOutputModule(outLayer)

in_to_hidden = FullConnection(inLayer, hiddenLayer)
bias_to_hidden = FullConnection(bias, hiddenLayer)
hidden_to_out = FullConnection(hiddenLayer, outLayer)

network.addConnection(in_to_hidden)
network.addConnection(bias_to_hidden)
network.addConnection(hidden_to_out)

network.sortModules()
```

trainer.py

```
#!/usr/bin/python

from pybrain3.supervised.trainers import BackpropTrainer
from pybrain3.tools.validation import Validator

import inputLetters
import network

trainer = BackpropTrainer(network.network,
inputLetters.inputLettersDataSet, learningrate=0.1, verbose=True)

trainer.trainEpochs(2000)

testInput = inputLetters.inputLettersDataSet['input']
testTarget = inputLetters.inputLettersDataSet['target']
errorComparator = 0.900

print("Number of training patterns:",
len(inputLetters.inputLettersDataSet))
```

```
letters = ["A", "B", "C", "D", "I", "F", "G", "H", "K", "U", "a", "b", "c",
"d", "f", "h", "m", "o", "w", "z"]

MSE = 0

for i in range(20):
    temp = network.network.activate(testInput[i])
    print("For letter", letters[i], "precision is", temp[0])
    print("MSE:", Validator.MSE(network.network.activate(testInput[i]),
testTarget[i]))
    MSE += Validator.MSE(network.network.activate(testInput[i]),
testTarget[i])
    if errorComparator < temp:
        print("Letter", letters[i], "is capital letter")
    else:
        print("Letter", letters[i], "is small letter")

print("MSE: ", (MSE/20))
```